

Επεξεργασία Φυσικής Γλώσσας

Εργαστήριο 2

Άγγελος Μαρινάκης
ΕΔΕΜΜ
03400225

Λάζαρος Αθανασιάδης
ΕΔΕΜΜ
03400201

Περιεχόμενα

1 Προπαρασκευή Εργαστηρίου	2
1.1 Ερωτήσεις προπαρασκευής	2
1.2 Προεπεξεργασία Δεδομένων	3
1.2.1 Κωδικοποίηση Επισημειώσεων	3
1.2.2 Λεκτική Ανάλυση	3
1.2.3 Κωδικοποίηση Παραδειγμάτων	4
1.3 Μοντέλο	6
1.3.1 Embedding Layer	6
1.3.2 Output Layers	6
1.3.3 Forward Pass	6
1.4 Διαδικασία Εκπαίδευσης	6
1.4.1 Φόρτωση Παραδειγμάτων	6
1.4.2 Βελτιστοποίηση	6
1.4.3 Εκπαίδευση	6
1.4.4 Αξιολόγηση	6
1.5 Κατηγοριοποίηση με χρήση LLM	8
1.5.1 MR Dataset	8
1.5.2 Semeval Dataset	10
2 Κυρίως Μέρος	13
2.1 Mean και Max pooling	13
2.2 LSTM	14
2.3 Απλός Μηχανισμός Attention	14
2.4 Multi-Head Attention	15
2.5 Transformer-Encoder	16
2.6 Χρήση Προεκπαιδευμένων Μοντέλων	16
2.7 Κούρδισμα Προεκπαιδευμένων Μοντέλων	18
2.8 Χρήση ChatGPT	19
2.8.1 Περιγραφή κώδικα	19
2.8.2 Αξιολόγηση κώδικα	20
2.8.3 Βελτίωση κώδικα	21

1 Προπαρασκευή Εργαστηρίου

1.1 Ερωτήσεις προπαρασκευής

Γιατί αρχικοποιούμε το embedding layer με τα προ-εκπαιδευμένα word embeddings?

Τα προ-εκπαιδευμένα word embeddings είναι αναπαραστάσεις των λέξεων που έχουν μαθευτεί από μεγάλο όγκο γραπτού λόγου και έτσι περιέχουν πολλή πληροφορία σχετικά με την σημασία των λέξεων και τη χρήση τους στη γλώσσα. Αποτελούν έτσι πολύ χρήσιμα χαρακτηριστικά εισόδου (features) πάνω στα οποία μπορούμε να βασιστούμε για να μάθουμε νέες αναπαραστάσεις.

Γιατί κρατάμε παγωμένα τα βάρη του embedding layer κατά την εκπαίδευση;

Τα βάρη του embedding layer παραμένουν παγωμένα κατά την εκπαίδευση καθώς τα embeddings έχουν ήδη μαθευτεί από διαδικασία εκπαίδευσης και δεν θέλουμε να τα εκπαιδεύσουμε εκ νέου. Τα θεωρούμε ως features εισόδου για το μοντέλο μας.

Γιατί βάζουμε μία μη γραμμική συνάρτηση ενεργοποίησης στο προτελευταίο layer; Τι διαφορά θα είχε αν είχαμε 2 ή περισσότερους γραμμικούς μετασχηματισμούς στη σειρά;

Η σύνθεση γραμμικών μετασχηματισμών είναι και αυτή γραμμικός μετασχηματισμός, οπότε με το να έχουμε πολλούς γραμμικούς μετασχηματισμούς στη σειρά δεν κερδίζουμε πολλά σε εκφραστική δύναμη του δικτύου. Στα νευρωνικά δίκτυα είναι σημαντικό να υπάρχει μη γραμμικότητα έτσι ώστε αυτά να μην είναι απλώς ένας γραμμικός μετασχηματισμός και να μπορούν να αναπαραστήσουν μη γραμμικές σχέσεις.

Αν θεωρήσουμε ότι κάθε διάσταση του embedding χώρου αντιστοιχεί σε μία αφηρημένη έννοια, μπορείτε να δώσετε μία διαισθητική ερμηνεία για το τι περιγράφει η αναπαράσταση που φτιάξατε (κέντρο-βάρους);

Κάθε διάσταση του embedding χώρου μπορεί να αντιστοιχεί σε κάποιο αφηρημένο χαρακτηριστικό που περιγράφει μια λέξη, όπως για παράδειγμα πόσο χαρούμενο ή λυπητερό συναίσθημα έχει, πόσο σοβαρή ή χιουμοριστική σημασία έχει κλπ. Έτσι κάθε συντεταγμένη του μέσου όρου (κέντρου βάρους) των embeddings μας δείχνει κατά πόσο περιέχεται το αντίστοιχο χαρακτηριστικό στην πρόταση ή το κείμενο κατά μέσο όρο.

Αναφέρετε πιθανές αδυναμίες της συγκεκριμένης προσέγγισης για να αναπαραστήσουμε κείμενα.

Η αναπαράσταση ενός κειμένου με τον μέσο όρο των embeddings μπορεί να είναι πολύ απλουστευτική, καθώς λαμβάνει υπόψιν κάθε λέξη μεμονομένα και έτσι αγνοεί τις σχέσεις μεταξύ των λέξεων και το πως αλλάζει η σημασία τους ανάλογα με τα συμφραζόμενα. Επιπλέον, όλες οι λέξεις λαμβάνουν την ίδια βαρύτητα, ενώ κάποιες μπορεί να είναι πιο σημαντικές από άλλες.

Τι συνέπειες έχουν τα μικρά και μεγάλα mini-batches στην εκπαίδευση των μοντέλων;

Τα μικρά batches προσθέτουν μεγαλύτερη τυχαιότητα στον τρόπο που γίνεται η εκπαίδευση. Αυτό μπορεί να έχει θετικές συνέπειες, όπως ότι μπορεί να είναι ευκολότερο να αποφύγουμε τοπικά ελάχιστα του σφάλματος, αλλά και αρνητικές, όπως ότι η μπορεί να υπάρχει απόκλιση αν δεν γίνει σωστή ρύθμιση του ρυθμού μάθησης. Αντίθετα, τα μεγάλα batches προσεγγίζουν καλύτερα το

πραγματικό σφάλμα πάνω από όλα τα δεδομένα, οπότε η σύγκλιση θα γίνει με πιο προβλέψιμο και λιγότερο τυχαίο τρόπο, αυτό όμως μπορεί να σημαίνει μεγαλύτερη δυσκολία να αποφύγουμε κάποιο τοπικό ελάχιστο.

Συνήθως ανακατεύουμε την σειρά των mini-batches στα δεδομένα εκπαίδευσης σε κάθε εποχή. Μπορείτε να εξηγήσετε γιατί;

Τα δείγματα ανακατεύονται σε κάθε εποχή καθώς δεν θέλουμε η εκπαίδευση να γίνει με μεροληπτικό τρόπο προς μια συγκεκριμένη σειρά των δεδομένων. Για παράδειγμα δεν θα θέλαμε το μοντέλο μας να μάθει αναπαραστάσεις που έχουν σχέση με την σειρά των δεδομένων, καθώς αυτό θα οδηγήσει σχεδόν σίγουρα σε overfitting.

1.2 Προεπεξεργασία Δεδομένων

1.2.1 Κωδικοποίηση Επισημειώσεων

Χρησιμοποιώντας το LabelEncoder της sklearn, κωδικοποιήσαμε τις επισημειώσεις (labels) των δεδομένων σε αριθμούς.

```
1 Encoded 2 classes
2 positive -> 1
3 positive -> 1
4 positive -> 1
5 positive -> 1
6 positive -> 1
7 positive -> 1
8 positive -> 1
9 positive -> 1
10 positive -> 1
11 positive -> 1
```

Listing 1: Οι κωδικοποιήσεις των 10 πρώτων κριτικών από το Sentence Polarity Dataset.

Παρατηρούμε πως οι επισημάνσεις που αντιστοιχούν στις θετικές κριτικές αντιστοιχούν στο 1, άρα οι αρνητικές έχουν κωδικοποιηθεί με το 0. Τα δεδομένα του MR dataset δεν είναι ανακατεμένα, όμως αυτό δεν θα δημιουργήσει θέμα καθώς ανακατεύουμε την σειρά των mini-batches κατά την διάρκεια της εκπαίδευσης (βλ. απάντηση στο ζ4).

1.2.2 Λεκτική Ανάλυση

Για το tokenization χρησιμοποιήσαμε την βιβλιοθήκη NLTK. Για το σύνολο δεδομένων MR, που έχει να κάνει με κριτικές ταινιών, χρησιμοποιήσαμε την γενικής χρήσης συνάρτηση word_tokenize. Για το σύνολο δεδομένων Semeval2017A που έχει να κάνει με tweets, χρησιμοποιήσαμε την κλάση TweetTokenizer ώστε να λάβει υπόψη τις ιδιαιτερότητές τους στο tokenization. Για παράδειγμα, οι χαρακτήρες "#cat" αναλύονται σε {#, cat} από τον πρώτο tokenizer αλλά σαν {#cat} από τον δεύτερο, επειδή τους αναγνωρίζει σαν hashtag.

```
1 Sentence: affable if not timeless , like mike raises some worthwhile themes while
   delivering a wholesome fantasy for kids .
2 Label: 1
```

```

3 Sentence: a film of delicate interpersonal dances . caine makes us watch as his
    character awakens to the notion that to be human is eventually to have to
    choose . it's a sight to behold .
4 Label: 1
5 Sentence: it's an unusual , thoughtful bio-drama with a rich subject and some
    fantastic moments and scenes .
6 Label: 1
7 Sentence: saved from being merely way-cool by a basic , credible compassion .
8 Label: 1
9 Sentence: the increasingly diverse french director has created a film that one can
    honestly describe as looking , sounding and simply feeling like no other film
    in recent history .
10 Label: 1
11 Sentence: gangs , despite the gravity of its subject matter , is often as fun to
    watch as a good spaghetti western .
12 Label: 1
13 Sentence: peter jackson has done the nearly impossible . he has improved upon the
    first and taken it a step further , richer and deeper . what jackson has done
    is proven that no amount of imagination , no creature , no fantasy story and no
    incredibly outlandish scenery
14 Label: 1
15 Sentence: there has to be a few advantages to never growing old . like being able
    to hit on a 15-year old when you're over 100 .
16 Label: 1
17 Sentence: ice age won't drop your jaw , but it will warm your heart , and i'm
    giving it a strong thumbs up .
18 Label: 1
19 Sentence: like kissing jessica stein , amy's orgasm has a key strength in its
    willingness to explore its principal characters with honesty , insight and
    humor .
20 Label: 1

```

Listing 2: Οι πρώτες δέκα κριτικές από το Sentence Polarity Dataset και οι επισημάνσεις τους.

1.2.3 Κωδικοποίηση Παραδειγμάτων

Σε αυτό το βήμα κάναμε τις απαραίτητες αλλαγές στην κλάση `SentenceDataset`. Επιπλέον, παρατηρήσαμε πως το σύνολο δεδομένων `SemEval2017A` περιέχει λέξεις με κεφαλαίους χαρακτήρες, οπότε αλλάξαμε την `load_SemEval2017A` ώστε να τους μετατρέπει σε πεζούς. Με αυτόν τον τρόπο βρίσκουμε το `embedding` τους με εύκολο τρόπο, καθώς το `dictionary word2idx` έχει ως κλειδιά λέξεις μόνο με πεζούς χαρακτήρες.

Ως μέγιστο μήκος πρότασης, χρησιμοποιήσαμε το q -quantile των μηκών των ακολουθιών των παραδειγμάτων (σε `tokens`, για ευκολία). Δοκιμάσαμε $q = 0.9$ και $q = 0.99$.

```

1 Example #1

```

```

2 @seemonterey lost - sony cell phone with holiday photos. early fri morning,
   montreal transit plaza or no. 13 bus to airport. reward! plz rt.
3 (array([400001,    403,    12,   4503,   2115,   1265,    18,   2333,
4         2671,     3,   200,  18131,   767,     2,   4021,   4563,
5         6751,    47,    85,     3,   677,   1709,     5,    923,
6         3,   6596,   806, 395112, 33223,     3]), 1, 30)
7 Example #2
8 @personasoda well yeah, that's third parties. sony itself isn't putting out actual
   games for it. it's got 1-2 yrs of 3rd party support left.
9 (array([400001,   144,   8739,     2, 400001,   246,   936,     3,
10         4503,   1004, 400001,   2221,    67,   3571,   291,    11,
11         21,     3, 400001,    406,   9565,  80747,     4,   4054,
12        166,   281,   219,     3,     0,     0]), 1, 28)
13 Example #3
14 sony rewards app is like a lot of 19 y.o female singers and a non retro sale. 2nd
   one with no info
15 (array([ 4503, 10816, 14673,    15,   118,     8,   531,     4,   905,
16         3525,     3,   4869,  1633,  7793,     6,     8,  1338, 19939,
17         1564,     3,   2767,    49,    18,    85, 14036,     0,     0,
18         0,     0,     0]), 0, 25)
19 Example #4
20 @fakethom have android tab and don't use phone much, in fact very little. may go
   the sony route then:-)
21 (array([400001,    34,  17679,  17318,     6, 400001,   235,   1265,
22         182,     2,     7,   854,   192,   334,     3,   108,
23         243,     1,   4503,  1315,   128, 256537,     0,     0,
24         0,     0,     0,     0,     0,     0]), 1, 22)
25 Example #5
26 finally i get my ps4 back i sent it to sony cause my hdmi was mess up now i can
   play mg's tuesday yeaaaaa buddy
27 (array([ 1230,    42,   170,   193, 281436,   138,    42,   689,
28         21,     5,   4503,  1158,   193,  73335,   16,   7563,
29         61,   115,    42,    87,   283, 400001,   172, 400001,
30        9551,     0,     0,     0,     0,     0]), 2, 25)

```

Listing 3: Τα 5 πρώτα tweets από το Semeval2017A dataset και η μορφή με την οποία τα επιστρέφει η SentenceDataset

Παρατηρούμε πως mentions σε άλλους χρήστες (π.χ @personasoda) ή ανεπίσημες μορφές κάποιων εκφράσεων (π.χ yeaaaaa) κωδικοποιούνται με το embedding που αντιστοιχεί στο <unk>, δηλαδή το 400001.

1.3 Μοντέλο

1.3.1 Embedding Layer

Για να αρχικοποιήσουμε το embedding layer με προεκπαιδευμένα βάρη, χρησιμοποιούμε την `from_pretrained` class method του `torch.nn.Embedding`. Επιπλέον, θέτουμε ως `True` το όρισμα `freeze` ώστε να "παγώσουμε" αυτό το επίπεδο και να μην το εκπαιδεύσουμε περαιτέρω.

1.3.2 Output Layers

Το κρυφό επίπεδο που χρησιμοποιήσαμε είναι μια γραμμική στρώση εισόδου d_e και εξόδου d_h ακολουθούμενο από την ReLU συνάρτηση ενεργοποίησης. Με d_e συμβολίζουμε την διάσταση των embeddings και με d_h την διάσταση του κρυφού επιπέδου, η οποία αποτελεί μια υπερπαραμέτρο του μοντέλου.

Τέλος, ακολουθεί μια δεύτερη γραμμική στρώση με διάσταση εισόδου d_h και διάσταση εξόδου 2 ή 3, ανάλογα με το πλήθος των κλάσεων που θέλουμε να προβλέψουμε.

1.3.3 Forward Pass

Στην συνάρτηση `forward`, εκτός από την διαπέραση της εισόδου από όλο το δίκτυο, φροντίζουμε να εξάγουμε το representation της με `average pooling`.

1.4 Διαδικασία Εκπαίδευσης

1.4.1 Φόρτωση Παραδειγμάτων

Σε αυτό το βήμα χρησιμοποιήσαμε την συνάρτηση `torch_train_val_split` που μας δίνεται για να χωρίσουμε το `train set` σε `train` και `validation set`. Στην διαδικασία εκπαίδευσης, χρησιμοποιούμε την αύξηση του `loss` στο `validation set` ως ένδειξη για το πότε πρέπει να κάνουμε `early stop`. Για το `test set` χρησιμοποιήσαμε κατευθείαν τον constructor των `DataLoaders` του `torch`.

1.4.2 Βελτιστοποίηση

Χρησιμοποιήσαμε την `CrossEntropyLoss` ως κριτήριο και για την περίπτωση που έχουμε μόνο 2 κλάσεις, καθώς λειτουργεί και σε αυτήν. Επιπλέον, έχει το χρήσιμο χαρακτηριστικό πως μπορεί να δέχεται σαν είσοδο `labels` αντί για `one-hot` διανύσματα, κάτι που δεν ισχύει για την `BCEWithLogitsLoss`. Σαν `optimizer` χρησιμοποιήσαμε τον `Adam`, εξαιρώντας το `embedding layer` από τις παραμέτρους προς εκπαίδευση στα ορίσματά του.

1.4.3 Εκπαίδευση

Συμπληρώσαμε τα απαραίτητα κενά στο `training.py` ώστε το δίκτυο να εκπαιδεύεται.

1.4.4 Αξιολόγηση

Αξιολογήσαμε το μοντέλο στα δυο συνολα δεδομένων για δυο τιμές των υπερπαραμέτρων που ορίσαμε (q , d_h - βλ. Ενότητες 1.2.3 και 1.3.2).

Βλέπουμε πως η χρήση του 0.9-quantile του μήκος των προτάσεων είναι αρκετό, καθώς το 0.99 δεν βελτιώνει κάποια από τις μετρικές. Επιπλέον, παρατηρούμε πως η αύξηση της διάστασης της κρυφής στρώσης δεν βελτιώνει την επίδοση του μοντέλου, το οποίο μας κάνει να υποψιαζόμαστε πως οι μετρικές αυτές είναι κοντά στο βέλτιστο για την αρχιτεκτονική του μοντέλου (μία κρυφή στρώση με ReLU).

Dataset \ d_h	200	1000
MR	70.39%	70.7%
Semeval2017A	59.79%	58.41%

(α') Accuracy, $q=90\%$

Dataset \ d_h	200	1000
MR	69.94%	69.34%
Semeval2017A	58.44%	58.24%

(β') Accuracy, $q=99\%$

Dataset \ d_h	200	1000
MR	70.67%	70.76%
Semeval2017A	58.88%	57.64%

(α') Recall, $q=90\%$

Dataset \ d_h	200	1000
MR	70.01%	69.38%
Semeval2017A	57.36%	57.45%

(β') Recall, $q=99\%$


Dataset \ d_h	200	1000
MR	70.29%	70.67%
Semeval2017A	57.74%	56.18%

(α') F1-score, $q=90\%$

Dataset \ d_h	200	1000
MR	69.91%	69.32%
Semeval2017A	56.54%	56.21%

(β') F1-score, $q=99\%$

Στο Σχήμα 1 παρουσιάζουμε μια γραφική παράσταση στην οποία παρουσιάζεται το training και το validation loss, καθώς και πότε γίνεται το early stop. Πρόκειται για εκπαίδευση στο MR dataset με $q = 0.9$ και $d_h = 200$. Το μοτίβο που παρουσιάζει εμφανίζεται σε όλες τις εκπαιδεύσεις feedforward δικτύων που κάναμε.



Σχήμα 1: Τυπικές καμπύλες training και validation loss

1.5 Κατηγοριοποίηση με χρήση LLM

1.5.1 MR Dataset

Αρχίσαμε με το prompt "Can you classify some movie reviews as positive or negative? Replying with just the classification will suffice."

1. the rock is destined to be the 21st century's new " conan " and that he's going to make a splash even greater than arnold schwarzenegger , jean-claud van damme or steven segal .

Positive

2. the gorgeously elaborate continuation of " the lord of the rings " trilogy is so huge that a column of words cannot adequately describe co-writer/director peter jackson's expanded vision of j . r . r . tolkien's middle-earth .

Positive

3. there is a difference between movies with the courage to go over the top and movies that don't care about being stupid

Negative

4. nothing here seems as funny as it did in analyze this , not even joe viterelli as de niro's right-hand goombah .

Negative

5. a farce of a parody of a comedy of a premise , it isn't a comparison to reality so much as it is a commentary about our knowledge of films .

Negative

6. ultimately , it ponders the reasons we need stories so much .

Positive

7. an utterly compelling 'who wrote it' in which the reputation of the most famous author who ever lived comes into question .

Positive

8. a disturbing and frighteningly evocative assembly of imagery and hypnotic music composed by philip glass .

Positive

9. not for everyone , but for those with whom it will connect , it's a nice departure from standard moviegoing fare .

Positive

10. spiderman rocks

Positive

11. the only surprise is that heavyweights joel silver and robert zemeckis agreed to produce this ; i assume the director has pictures of them cavorting in ladies' underwear .

Negative

12. though it is by no means his best work , laissez-passar is a distinguished and distinctive effort by a bona-fide master , a fascinating film replete with rewards to be had by all willing to make the effort to reap them .

Positive

13. curling may be a unique sport but men with brooms is distinctly ordinary .

Negative

14. newton draws our attention like a magnet , and acts circles around her better known co-star , mark wahlberg .

Positive

15. gosling provides an amazing performance that dwarfs everything else in the film .

Positive

16. the lack of naturalness makes everything seem self-consciously poetic and forced . . . it's a pity that [nelson's] achievement doesn't match his ambition .

Negative

17. the country bears has no scenes that will upset or frighten young viewers . unfortunately , there is almost nothing in this flat effort that will amuse or entertain them , either .

Negative

18. may be spoofing an easy target -- those old '50's giant creature features -- but . . . it acknowledges and celebrates their cheesiness as the reason why people get a kick out of watching them today .

Positive

19. singer/composer bryan adams contributes a slew of songs — a few potential hits , a few more simply intrusive to the story — but the whole package certainly captures the intended , er , spirit of the piece .

Positive

20. watching the chemistry between freeman and judd , however , almost makes this movie worth seeing . almost .

Positive

Το μοντέλο έκανε λάθος μόνο στην τελευταία ταξινόμηση. Ζητήσαμε να μας εξηγήσει το "σκεπτικό" του με το prompt "For the last review, can you explain your reasoning behind the classification? Where there any words that were more important for it than others?"

Certainly! In the last review, the phrase "watching the chemistry between Freeman and Judd" suggests a positive aspect of the movie. When two actors have good chemistry on screen, it often enhances the viewing experience. However, the word "almost" in "almost makes this movie worth seeing" tempers the positivity, indicating that while the chemistry between Freeman and Judd is a highlight, it's not enough to fully redeem the movie. Overall, the positive aspect of the chemistry between the actors outweighs the slight negativity expressed by "almost," leading to a positive classification.

Βλέπουμε πως το μοντέλο έχει εντοπίσει σωστά ότι η λέξη "almost" είναι σημαντική, αλλά δεν αποτίμησε σωστά την επίδρασή της, πιστεύοντας πως η καλή χημεία μεταξύ των ηθοποιών είναι πιο σημαντική.

Επιπλέον, χρησιμοποιήσαμε το ίδιο prompt αφού ζητήσαμε ταξινόμηση για το ακόλουθο review: "part of the charm of satin rouge is that it avoids the obvious with humour and lightness ."

Absolutely! In this review, several words contribute to the positive classification:

- "Charm": This word implies that there's something endearing or delightful about the film.
- "Avoids the obvious": This suggests that the film is not predictable or clichéd, which can be a positive attribute in storytelling.
- "Humour and lightness": These qualities indicate that the film has a light-hearted and amusing tone, which tends to be positively received by audiences.

Overall, the combination of these words paints a picture of a film that is charming, unpredictable, and enjoyable, leading to a positive classification.

Όπως και στην προηγούμενη πρόταση, το μοντέλο εντόπισε τα σημαντικά σημεία της πρότασης.

1.5.2 Semeval Dataset

Σε αυτό το ερώτημα, χρησιμοποιήσαμε το prompt "Can you classify some tweets as positive, neutral or negative? Replying with just the classification will suffice. "

1. Put my Michael Jackson playlist on and cleaned the hell out of my house. Gonna be a great Saturday.

Positive

2. I may have a treat for you guys tonight so you can play some Minecraft with me ;) #TheDream

Positive

3. @Maxusy Is Minecraft the only program you have issues with? If so, you may need to contact Minecraft support for your issue.

Neutral

4. 3rd creeper base explosion because Tommy wouldn't give me everything I had ever gathered in the game. I am so done with Minecraft

Negative

5. Off to bed but looking forward to flumps and playing Minecraft with Martin and Chloe tomorrow ... Hmmm minecraft flump? #flumplover #minecraft

Positive

6. Any of you will to watch Minecraft and have Half-life on Friday? Cause that's the only game that's ready to stream that I am willing to play

Neutral

7. Surprise! Monsanto Says, "No Glyphosate in Breast Milk".: On July 23, WSU posted the news th... <http://t.co/kcLdPb8zyH> via @MarchingMoms

Neutral

Αυτό ήταν το πρώτο λάθος που έκανε το μοντέλο, οπότε ζητήσαμε να αναλύσει τους λόγους που έδωσε αυτήν την απάντηση, χρησιμοποιώντας το prompt που δώσαμε σε αυτήν την περίπτωση στο προηγούμενο ερώτημα.

The last tweet was classified as neutral because it reports news without expressing a clear personal opinion or emotional tone. The tweet simply relays information about Monsanto's statement regarding glyphosate in breast milk and provides a link for more details. There are no strongly positive or negative words or phrases; it is informational in nature.

Παρατηρούμε πως το μοντέλο ερμήνευσε το tweet ως ουδέτερο επειδή θεωρεί ότι αποτελεί απλή αναμετάδοση των ειδήσεων.

8. Monsanto (MON), the world's biggest seed company hostile bid for rival Syngenta AG (SYT)! <http://t.co/IyDdsLYEKT> <http://t.co/Z2UOLHbhfH>

Neutral

9. @BlissTabitha I would bet that Monsanto factors into this somehow! Obvious they want to control the food supply even if it may cause cancer

Negative

10. Too hot. Too cold. Rain. Sun. Snow. Clear. People always have an excuse not to vote. Online you say? Nah, I'm watching Netflix.

Negative

Καθώς το σωστό label είναι το "positive", ζητήσαμε ξανά από το μοντέλο να εξηγήσει το σκεπτικό του:

The tweet was classified as negative because it expresses frustration and cynicism towards people's excuses for not voting. The tone suggests a sense of resignation or annoyance, implying that people prioritize entertainment (such as watching Netflix) over civic engagement. Words like "excuse," "nah," and the dismissive tone towards voting and online engagement contribute to the negative classification.

Βλέπουμε πως η ερμηνεία που δόθηκε στο tweet ήταν πως αυτό ήταν σαρκαστικό προς τα άτομα που δεν ψηφίζουν. Το μοντέλο, δηλαδή, δεν κατάλαβε τον χιουμοριστικό χαρακτήρα του κειμένου.

11. I got my 1st achievement on the xbox one: watch Netflix 7 days in a row.

Neutral

Όπως και στο προηγούμενο tweet με την είδηση, το μοντέλο ερμήνευσε με ουδέτερο τρόπο ένα κείμενο με θετικό συναίσθημα. Η εξήγηση που δόθηκε:

The tweet was classified as neutral because it simply states a personal achievement without expressing a clear positive or negative sentiment. The achievement of watching Netflix for seven days in a row is presented matter-of-factly without additional commentary. Words like "achievement" and "Xbox One" indicate a sense of accomplishment, but the overall tone remains neutral as there is no explicit emotional leaning towards positivity or negativity.

Με αυτήν την εξήγηση παρατηρούμε πως η ερμηνεία των κειμένων γίνεται με κυριολεκτικό τρόπο, οπότε η απουσία λέξεων που χαρακτηρίζουν θετικά ή αρνητικά συναισθήματα οδηγεί σε ουδέτερη ταξινόμηση, ακόμη και αν παρουσιάζουν κάτι ευχάριστο.

12. Since we're doing nothing in 6th hour I'm just gonna watch Netflix :-)

Positive

13. I love my Nike players!! Way to go Serena! Expecting great things from you tomorrow, federer!

14. Officially out of office hours until the 8th! In my back pack: Nintendo and Mario Bross YES Mp3 YES Bikini YES... <http://t.co/IhpcPORgBG>

Positive

15. @DanteReborn I honestly think the Super Mario Bros 2 set is coming. Nintendo wanted to concentrate development on the more-similar sets 1st

Neutral

Το μοντέλο έδωσε ουδέτερη αντί για θετική ταξινόμηση σε αυτό το tweet, όμως λόγω της φύσης του θα μπορούσαν να θεωρηθούν και τα δύο labels σωστά.

16. #game Indiana Jones and the Temple of Doom (Nintendo NES, 1988): \$5.95End Date: Saturday Sep-12-2015 ... <http://t.co/v1uDRctW7t> #eBayUS

Neutral

17. Replacing the screen on the Nokia 1020 went.... badly. Luckily new phone arrives tomorrow!

Negative

Το σωστό label εδώ ήταν το Positive. Εξήγηση:

The tweet was classified as negative because it conveys a sense of frustration or disappointment due to the unsuccessful attempt to replace the screen on a Nokia 1020. The word "badly" suggests that the outcome was not as desired or expected, indicating a negative experience. Additionally, the need for a new phone to arrive implies inconvenience and added hassle, further contributing to the negative sentiment.

Από την επεξήγηση του μοντέλου, υποψιαζόμαστε πως το μοντέλο ταξινόμησε το tweet ως αρνητικό επειδή έδωσε περισσότερο βάρος στο πρώτο μέρος του και ερμήνευσε με διαφορετικό τρόπο το υπόλοιπο. Η περίπτωση αυτή είναι ενδιαφέρουσα καθώς προσπάθησε να βρει το υπονοούμενο της δεύτερης πρότασης ("implies inconvenience and added hassle"), χάνοντας όμως το αρχικό νόημα στην πορεία.

18. From the Archives: : Nokia Lumia 800: Monday Morning Surprise <http://t.co/qy3NO16nCo> #gadgetreview #mobile

Neutral

Η σωστή κατηγορία εδώ ήταν η θετική. Εξήγηση:

The tweet was classified as neutral because it simply shares a link to an article or content related to the Nokia Lumia 800 without expressing a clear positive or negative sentiment. The words "From the Archives" and "Monday Morning Surprise" suggest a retrospective or nostalgic tone, but overall, the tweet does not convey a strong emotional stance. It appears to be informational rather than opinionated, hence the neutral classification.

Για άλλη μια φορά επιδεικνύεται η δυσκολία του μοντέλου να δώσει θετική ή αρνητική ταξινόμηση σε tweets που αποτελούν αναπαραγωγή πληροφοριών αλλά με συγκεκριμένη χροιά.

19. debating on skipping class tomorrow bc I don't wanna deal with all the crazy people bc Obama

Negative

20. A real and sustained #WarOnWomen from the regime Obama is giving \$\$ and nuke capabilities to. May God forgive us all <https://t.co/hfP84knjYo>

Negative

Το μοντέλο απάντησε σωστά για αυτό το tweet. Ζητήσαμε να αναλύσει το σκεπτικό του, με το ίδιο prompt, για να δούμε τι θα απαντήσει σε αυτήν την περίπτωση.

The tweet was classified as negative because it presents a critical view of the Obama administration's actions, specifically regarding women's issues and international relations. The use of the hashtag #WarOnWomen suggests a perception of systemic oppression or discrimination against women, which is attributed to the Obama administration. Phrases like "regime Obama" and "giving \$\$ and nuke capabilities" imply a negative judgment of the administration's policies. Additionally, the expression "May God forgive us all" conveys a sense of concern or despair about the perceived consequences of these actions. Overall, the tweet expresses a negative sentiment towards the Obama administration's policies and their impact on women.

Το μοντέλο έχει εντοπίσει και ερμηνεύσει με σωστό τρόπο τα σημαντικά στοιχεία του tweet.

Όπως και τα feedforward μοντέλα που δοκιμάσαμε, το GPT3.5 δυσκολεύεται περισσότερο στην ταξινόμηση των tweets από την ταξινόμηση των κριτικών ταινιών. Εκτός από την αυξημένη δυσκολία της ταξινόμησης τριών κλάσεων αντί για δύο, δεν έχουν όλα τα tweets ξεκάθαρο σκοπό, σε αντίθεση με τις κριτικές ταινιών, οι οποίες είναι είτε θετικές είτε αρνητικές στην πλειοψηφία τους.

2 Κυρίως Μέρος

2.1 Mean και Max pooling

Σε αυτό το βήμα η αναπαράσταση που χρησιμοποιούμε για κάθε πρόταση προέρχεται από την συνένωση των mean και max poolings των λέξεων κάθε πρότασης. Για να λειτουργεί το δίκτυο της προπαρασκευής, πρέπει να αλλάξουμε ορίσουμε την διάσταση της εισόδου στο γραμμικό επίπεδο σε $2 \times d_e$, όπου d_e είναι η διάσταση των embeddings. Η αλλαγή αυτή δεν προσέδωσε κάποια ουσιαστική βελτίωση σε μία από τις τρεις μετρικές (F1-score, accuracy, recall).

Σχετικά με την αναπαράσταση που χρησιμοποιούμε για τις προτάσεις, αν θεωρήσουμε ότι κάθε άξονας του embedding χώρου αντιστοιχεί σε κάποιο αφηρημένο χαρακτηριστικό που περιγράφει μια λέξη, τότε η αναπαράσταση με το μέγιστο ανά διάσταση μας δείχνει τον μέγιστο βαθμό κάθε χαρακτηριστικού που περιέχει η πρόταση ή το κείμενο. Η συνένωση (concatenation) μέσου όρου και μεγίστου ανα διάσταση είναι μια καλύτερη αναπαράσταση από την χρήση μόνο του μέσου όρου, καθώς μας δίνει επιπλέον πληροφορία για την μεταβλητότητα του κάθε χαρακτηριστικού μέσα στην πρόταση ή το κείμενο. Συχνά αυτά τα χαρακτηριστικά που περιέχονται σε μεγάλο/έντονο βαθμό μέσα σε ένα κείμενο είναι αυτά που το περιγράφουν/χαρακτηρίζουν καλύτερα.

2.2 LSTM

Για τα βήματα που αφορούν τα LSTM και το Attention, χρησιμοποιήσαμε το σύνολο δεδομένων Semeval, καθώς παρατηρήσαμε από την προπαρασκευή πως είναι αυτό με το οποίο τα feedforward νευρωνικά είχαν την μεγαλύτερη δυσκολία. Χρησιμοποιήσαμε τον EarlyStopper που μας δίνεται, όπως και στην προπαρασκευή. Επιπλέον, προσέξαμε ώστε να χρησιμοποιήσουμε μόνο την τελευταία έξοδο του LSTM ως την αναπαράσταση του κειμένου.

Model \ Metric	LSTM	Bidirectional LSTM
Accuracy	62.59%	63.20%
Precision	63.36%	62.26%
F1 Score	60.12%	62.07%

Παρατηρούμε πως τα LSTM μοντέλα πετυχαίνουν καλύτερη επίδοση σε σχέση με τα feedforward νευρωνικά που χρησιμοποιήσαμε στην προπαρασκευή. Βλέπουμε πως το bidirectional LSTM είχε ελαφρώς καλύτερη επίδοση. Όμως, λόγω του αυξημένου πλήθους παραμέτρων του, είναι και πιο επιρρεπές στο overfitting, καθώς σε κάποιες διαδικασίες εκπαίδευσης του μοντέλου, αυτό κατέληγε με τιμές κοντά στο 60% για τις μετρικές, δηλαδή χειρότερες από του απλού LSTM.

2.3 Απλός Μηχανισμός Attention

Σε αυτό το ερώτημα υπολογίσαμε το average pooling στο attention.py με τον ίδιο τρόπο που το είχαμε υπολογίσει για τα προηγούμενα δίκτυα. Όπως σε όλα τα δίκτυα ταξινόμησης, το τελευταίο επίπεδο του δικτύου είναι γραμμικό με την διάσταση εξόδου να είναι όσες και οι κλάσεις που θέλουμε να προβλέψουμε.

Model \ Metric	Simple Attention Model
Accuracy	62.18%
Precision	61.21%
F1 Score	60.91%

Παρατηρούμε πως αυτό το μοντέλο είχε καλύτερη επίδοση από το feedforward, αλλά χειρότερη από τα LSTM. Πιθανώς με tuning των υπερπαραμέτρων του feedforward δικτύου που ακολουθεί το attention head, ή των υπόλοιπων υπερπαραμέτρων του μοντέλου να πετύχαινε συγκρίσιμο αποτέλεσμα. Στην άσκηση ακολουθούμε την τακτική που έχει διαδωθεί από την πρώτη δημοσίευση για τους transformers και δοκιμάζουμε να χρησιμοποιήσουμε πολλά heads.

Ο μηχανισμός του attention προηγείται χρονικά από την αρχιτεκτονική των transformers. Στο απλό attention, πριν από τους transformers (π.χ για RNN ή LSTM μοντέλα), όλες οι έξοδοι του encoder μοντέλου χρησιμοποιούνται στον υπολογισμό των εξόδων του decoder μοντέλου.

Τα attention βάρη είναι (h^e οι κρυφές εξόδοι του encoder, αντίστοιχα h^d για τον decoder):

$$a_{ij} = \frac{\exp[h_{i-1}^d \cdot h_j^e]}{\sum_k \exp[h_{i-1}^d \cdot h_k^e]}$$

Δηλαδή, για κάθε κρυφή έξοδο του encoder, δίνουμε περισσότερη βάση στις εξόδους του decoder που είναι περισσότερο παρόμοιες με αυτήν. Συνήθως χρησιμοποιείται το εσωτερικό γινόμενο ως κριτήριο ομοιότητας, αλλά αυτό δεν είναι απαραίτητο.

Έχοντας υπολογίσει τα attention βάρη, μπορούμε να υπολογίσουμε το ακόλουθο context διάνυσμα για κάθε κατάσταση i του decoder:

$$c_i = \sum_j a_{ij} h_j^e$$

Έπειτα, αυτά τα διανύσματα λαμβάνονται υπόψη για τον υπολογισμό της επόμενης κρυφής εξόδου του decoder μοντέλου.

Μία από τις καινοτομίες της αρχιτεκτονικής των transformers είναι η ιδέα πως οι είσοδοι στο attention χρησιμοποιούνται για 3 σκοπούς:

- **Query:** η τωρινή εστίαση του μηχανισμού
- **Key:** παλιότερη είσοδος, σύγκριση με το query
- **Value:** χρήση της εισόδου για τον υπολογισμό της τελικής εξόδου (attention βάρη)

Για αυτόν τον λόγο ορίζονται τρεις γραμμικές στρώσεις με βάρη W^Q, W^K, W^V . Τα βάρη αυτά εκπαιδεύονται με σκοπό την εκμάθηση των διαφορετικών αναπαραστάσεων στις οποίες πρέπει να μετασχηματιστεί κάθε είσοδος, ανάλογα τον ρόλο που θα χρησιμοποιεί στον μηχανισμό του attention. Μετά από αυτές τις γραμμικές στρώσεις δεν ακολουθεί συνάρτηση ενεργοποίησης. Δηλαδή:

$$q_i = x_i W^Q, \quad k_i = x_i W^K, \quad v_i = x_i W^V$$

Με αυτούς τους μετασχηματισμούς, τα βάρη του attention υπολογίζονται με τον ακόλουθο τρόπο:

$$a_{ij} = \frac{\exp[q_i \cdot k_j]}{\sum_k \exp[q_i \cdot k_k]}$$

Και αντίστοιχα η έξοδος του μηχανισμού attention:

$$a_i = \sum_j a_{ij} v_j$$

2.4 Multi-Head Attention

Για μπορούμε να χρησιμοποιήσουμε όποιο πλήθος από heads θέλουμε, ορίσαμε τα heads να έχουν μέγεθος όσο η διάσταση των embeddings. Η αλλαγή αυτή απαιτεί και αλλαγή στην διάσταση εισόδου του γραμμικού επιπέδου προβολής των εξόδων των heads, καθώς τώρα πρέπει να γίνει $N_{\text{heads}} \times d_e$.

Παρατηρούμε πως την καλύτερη επίδοση την είχε το μοντέλο με τις 3 κεφαλές. Η επίδοση αυτή είναι συγκρίσιμη με την επίδοση του bidirectional LSTM μοντέλου. Ερμηνεύουμε την μείωση της επίδοσης του μοντέλου για 4 και 5 κεφαλές με δύο τρόπους. Πρώτον, υπάρχει το ενδεχόμενο του overfitting, καθώς αυξάνουμε το πλήθος των παραμέτρων του μοντέλου. Επιπλέον, ο χειρισμός της διάστασης των heads πιθανώς να μην είναι ο βέλτιστος. Στην κλασική transformer αρχιτεκτονική,

N_{heads} Metric	2	3	4	5
Accuracy	62.31%	63.11%	62.24%	60.49%
Precision	62.44%	63%	62.05%	62.12%
F1 Score	60.18%	60.99%	60.01%	57.16%

όπως δείχνουμε και στην επόμενη ενότητα, οι πίνακες Q , K , V προβάλλουν την είσοδο σε μικρότερη διάσταση, ενώ εμείς την μετασχηματίζουμε στον ίδιο αριθμό διαστάσεων.

2.5 Transformer-Encoder

Το Transformer-Encoder μοντέλο δεν είναι κάτι άλλο παρά από πολλά multi-head attention blocks στην σειρά. Διαχειριστήκαμε τις διαστάσεις των heads όπως και στο προηγούμενο ερώτημα.

N_{blocks} Metric	2	3	4
Accuracy	60.54%	61.84%	62.22%
Precision	64.41%	62.27%	64.87%
F1 Score	55.99%	59.39%	58.5%

Βλέπουμε πως για 2-4 layers, το μοντέλο είχε χειρότερη επίδοση από το multi-head attention του προηγούμενου ερωτήματος (για 3 κεφαλές). Η ερμηνεία αυτού του γεγονότος είναι η ίδια με του προηγούμενου ερωτήματος.

Οι τιμές των παραμέτρων στην κλασική αρχιτεκτονική του transformer είναι οι εξής:

- **Αριθμός Κεφαλών:** $h = 8$
- **Διάσταση Μοντέλου:** $d = 512$
- **Διάσταση Query και Key Embeddings:** $d_k = 64$
- **Διάσταση Value Embeddings:** $d_v = 64$
- **Αριθμός Encoder Επιπέδων:** $N = 6$
- **Αριθμός Decoder Επιπέδων:** $N = 6$

2.6 Χρήση Προεκπαιδευμένων Μοντέλων

Επιλέξαμε και δοκιμάσαμε 5 προεκπαιδευμένα μοντέλα για αναγνώριση συναισθήματος από την πλατφόρμα HuggingFace σε καθένα από τα δύο σύνολα δεδομένων MR και Semeval2017A. Στη συνέχεια αναφέρουμε τα μοντέλα που χρησιμοποιήσαμε και παραθέτουμε πίνακες με τα αποτελέσματα που πήραμε. Αναφερόμαστε σε κάθε μοντέλο χρησιμοποιώντας ένα απλό όνομα (πχ Twitter-roBERTa).

1. Twitter-roBERTa¹

Βασισμένο στο μοντέλο RoBERTa, εκπαιδευμένο σε 58M tweets και fine-tuned για αναγνώριση συναισθήματος.

¹<https://huggingface.co/cardiffnlp/twitter-roberta-base-sentiment>

2. RoBERTa-Large²

Βασισμένο στο μοντέλο RoBERTa-large και fine-tuned για αναγνώριση συναισθήματος σε διάφορα datasets όπως κριτικές και tweets. Το μοντέλο αυτό είναι το μοναδικό από τα 5 που ταξινομεί μόνο ως 'positive' ή 'negative' και δεν έχει 'neutral' κατηγορία.

3. BERTweet³

Βασισμένο στο μοντέλο BERTweet και εκπαιδευμένο πάνω στο Semeval2017, που είναι το ένα από τα δύο datasets που εξετάζουμε στην άσκηση.

4. FinancialBERT⁴

Μοντέλο BERT εκπαιδευμένο πάνω σε κείμενα οικονομικού περιεχομένου και fine-tuned στο dataset Financial PhraseBank για ανάλυση συναισθήματος.

5. Amazon Reviews⁵

Βασισμένο στο μοντέλο BERT-base και εκπαιδευμένο σε κριτικές προϊόντων της Amazon. Το συγκεκριμένο μοντέλο ταξινομεί χρησιμοποιώντας 1 έως 5 αστέρια, οπότε θεωρήσαμε ότι 1 ή 2 αστέρια αντιστοιχούν σε 'negative', 3 αστέρια σε 'neutral' και 4 ή 5 αστέρια σε 'positive'.

Πίνακας 1: Αποτελέσματα για το σύνολο δεδομένων MR

Model \ Metric	Twitter-roBERTa	RoBERTa-Large	BERTweet	FinancialBERT	Amazon Reviews
Accuracy	79.3%	92.5%	82.2%	57.4%	71.1 %
Precision	79.3%	92.5%	82.2%	57.4%	71.1%
F1 Score	79.2%	92.5%	82.2%	53.6%	69.9%

Πίνακας 2: Αποτελέσματα για το σύνολο δεδομένων Semeval2017A

Model \ Metric	Twitter-roBERTa	RoBERTa-Large	BERTweet	FinancialBERT	Amazon Reviews
Accuracy	72.3%	46.4%	72%	49.8%	36.1%
Precision	72.1%	60%	72.8%	37.7%	49.6%
F1 Score	72.2%	40%	72%	32.4%	33.3%

Βλέπουμε πως όλα τα μοντέλα έχουν καλύτερη απόδοση στο MR από ότι στο Semeval2017, κάτι που είναι λογικό καθώς στο MR έχουμε ένα ευκολότερο πρόβλημα δυαδικής ταξινόμησης (positive - negative), ενώ στο Semeval2017 έχουμε 3 κατηγορίες (positive - negative - neutral). Σημειώνουμε ότι καθώς το MR δεν έχει την κατηγορία 'neutral', για όσα μοντέλα προβλέπουν 3 κατηγορίες (δηλαδή για όλα πλην του RoBERTa-Large) επιλέγουμε απλώς την κατηγορία με το μεγαλύτερο score μεταξύ των 'positive' και 'negative'.

Όπως είναι αναμενόμενο τις καλύτερες αποδόσεις και στα δύο datasets πετυχαίνουν τα μοντέλα Twitter-roBERTa, RoBERTa-Large και BERTweet που είναι πιο γενικού σκοπού από τα άλλα δύο και επιπλέον είναι εκπαιδευμένα πάνω σε tweets. Μία εξαίρεση εδώ είναι ότι το μοντέλο RoBERTa-Large παρουσιάζει μέτρια απόδοση στο Semeval, όμως αυτό μπορούμε να το αποδώσουμε αποκλειστικά στο ότι όπως προαναφέραμε προβλέπει μόνο positive - negative κατηγορίες, οπότε αυτομάτως χάνει όσα tweets έχουν την επισήμανση neutral. Το γεγονός ότι προβλέπει μόνο δύο κατηγορίες πιθανώς παίζει ρόλο και στην εξαιρετική απόδοση που έχει στο MR.

²<https://huggingface.co/siebert/sentiment-roberta-large-english>

³<https://huggingface.co/finiteautomata/bertweet-base-sentiment-analysis>

⁴<https://huggingface.co/ahmedrachid/FinancialBERT-Sentiment-Analysis>

⁵<https://huggingface.co/LiYuan/amazon-review-sentiment-analysis>

Από τα άλλα δύο μοντέλα (FinancialBERT, Amazon Reviews) έχουμε μέτρια απόδοση λόγω της εξειδίκευσης τους σε συγκεκριμένες κατηγορίες κειμένων (οικονομικά και κριτικές προϊόντων αντίστοιχα). Εξαιρέση είναι το Amazon Reviews που παρουσιάζει κάπως καλύτερη απόδοση στο MR, κάτι που μπορούμε να το αποδώσουμε στις ομοιότητες που μπορεί να έχουν οι κριτικές προϊόντων με τις κριτικές ταινιών.

2.7 Κούρδισμα Προεκπαιδευμένων Μοντέλων

Σε αυτό το βήμα βασιστήκαμε κυρίως σε κάποια "base" προεκπαιδευμένα μοντέλα που παρέχει το HuggingFace (πχ bert-base-cased, roberta-base) ώστε δούμε κατά πόσο μπορούμε να βελτιώσουμε την απόδοσή τους στα datasets της άσκησης, κουρδίζοντάς τα (fine-tuning) πάνω σε αυτά. Παρακάτω έχουμε παραθέσει πίνακες με τα αποτελέσματα που πήραμε, χρησιμοποιώντας 3 μοντέλα για κάθε dataset και εκπαιδευοντάς τα για 5 εποχές το καθένα. Όσον αφορά τις υπερπαραμέτρους, πειραματιστήκαμε κυρίως με το learning rate. Η default τιμή του στο API του HuggingFace είναι $5 \cdot 10^{-5}$ αλλά είδαμε ότι μπορεί να χρειάζονται μικρότερες τιμές, έως και $5 \cdot 10^{-8}$. Είναι λογικό άλλωστε ένα μοντέλο που είναι προεκπαιδευμένο να χρειάζεται μια αρκετά μικρή τιμή learning rate για να εκπαιδευτεί περαιτέρω.

Στο MR καταφέραμε για τα base μοντέλα να βελτιώσουμε ικανοποιητικά την απόδοσή τους, όχι όμως και για το Roberta-Large που βελτιώθηκε ελάχιστα. Υποθέτουμε ότι επειδή το Roberta-Large είναι ένα ήδη κουρδισμένο μοντέλο, πιθανώς μάλιστα και στα dataset που χρησιμοποιούμε στην άσκηση, το επιπλέον κούρδισμα που δοκιμάσαμε δεν μπορεί να του προσφέρει πολλά.

Στο Semeval δεν είδαμε ανάλογη βελτίωση και είχαμε απροσδόκητα αποτελέσματα καθώς παρατηρήσαμε overfitting ήδη από την πρώτη εποχή, αφού το σφάλμα έπεφτε αρκετά γρήγορα στο training set όχι όμως και στο validation set, στο οποίο μάλιστα αυξανόταν. Πιθανώς να μην έγινε σωστή ρύθμιση των παραμέτρων εκπαίδευσης οπότε περισσότερος πειραματισμός ίσως να έφερνε καλύτερα αποτελέσματα.

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.404	0.406	0.907	0.907	0.907	0.907
2	0.365	0.412	0.912	0.912	0.912	0.912
3	0.332	0.409	0.912	0.912	0.912	0.912
4	0.329	0.406	0.913	0.912	0.912	0.912
5	0.330	0.411	0.913	0.913	0.913	0.913

Πίνακας 3: Κούρδισμα του Roberta-Large για το MR dataset

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.655	0.585	0.743	0.742	0.746	0.743
2	0.484	0.431	0.808	0.807	0.812	0.808
3	0.44	0.406	0.817	0.817	0.818	0.817
4	0.428	0.397	0.820	0.82	0.821	0.82
5	0.407	0.395	0.823	0.822	0.825	0.823

Πίνακας 4: Κούρδισμα του bert-base-cased για το MR dataset

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.641	0.528	0.796	0.794	0.802	0.796
2	0.446	0.4	0.832	0.831	0.837	0.832
3	0.401	0.387	0.836	0.836	0.838	0.836
4	0.382	0.39	0.845	0.845	0.846	0.845
5	0.366	0.392	0.845	0.845	0.846	0.845

Πίνακας 5: Κούρδισμα του roberta-base για το MR dataset

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.671	0.691	0.689	0.689	0.693	0.689
2	0.526	0.741	0.686	0.685	0.692	0.686
3	0.426	1.022	0.672	0.672	0.681	0.672
4	0.315	1.413	0.679	0.678	0.687	0.679
5	0.218	1.742	0.686	0.686	0.689	0.686

Πίνακας 6: Κούρδισμα του twitter-roberta-base-sentiment για το Semeval dataset

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.651	0.801	0.673	0.670	0.687	0.673
2	0.524	0.758	0.697	0.697	0.701511	0.697
3	0.399	1.002	0.685	0.685	0.687	0.685
4	0.288	1.422	0.693	0.693	0.696	0.693
5	0.167	1.671	0.687	0.687	0.691	0.687

Πίνακας 7: Κούρδισμα του bertweet-base-sentiment-analysis για το Semeval dataset

Epoch	Training Loss	Validation Loss	Accuracy	F1 Score	Precision	Recall
1	0.775	0.836	0.623	0.624	0.646	0.623
2	0.624	0.776	0.651	0.646	0.661	0.651
3	0.482	1.014	0.649	0.649	0.653	0.649
4	0.381	1.555	0.645	0.645	0.65	0.645
5	0.253	1.887	0.65	0.65	0.652	0.65

Πίνακας 8: Κούρδισμα του bert-base-cased για το Semeval dataset

2.8 Χρήση ChatGPT

Στον σύνδεσμο ⁶ μπορούμε να βρούμε ένα notebook με τον κώδικα από το tutorial του Andrej Karpathy με τίτλο “Let’s build GPT: from scratch, in code, spelled out” στο οποίο περιγράφεται βήμα προς βήμα η δημιουργία ενός GPT (Generative Pre-trained Transformer). Ζητήσαμε από το ChatGPT να περιγράψει, να αξιολογήσει και να προτείνει αλλαγές για αυτόν τον κώδικα και παραθέτουμε τις απαντήσεις του και σύντομο σχολιασμό της κάθε απάντησης.

2.8.1 Περιγραφή κώδικα

Αφού αντιγράψαμε τον κώδικα (από το κάτω μέρος του notebook όπου δίνεται ο τελικός κώδικας του tutorial σε ένα cell) στο πλαίσιο διαλόγου με το ChatGPT, δώσαμε το prompt "Can you describe the above code?". Παρακάτω είναι η απάντηση που πήραμε.

Certainly! This code implements a simple character-level language model using a Transformer

⁶https://colab.research.google.com/drive/1JMLa53HDuA-i7ZBmqV7ZnA3c_fvtXnx-

architecture, specifically a variation of it called the Bigram Language Model. Here's a breakdown of the code:

1. **Importing Libraries:** The code begins by importing necessary libraries including PyTorch.
2. **Hyperparameters:** Hyperparameters such as batch size, block size, learning rate, etc., are defined. These parameters control the training process and model architecture.
3. **Reading Text Data:** The code reads text data from a file (`input.txt`), tokenizes it into characters, and creates mappings between characters and their integer indices.
4. **Data Splitting:** The text data is split into training and validation sets.
5. **Model Components:**
 - **MultiHeadAttention:** Defines the multi-head self-attention mechanism used in the Transformer architecture.
 - **FeedForward:** Defines a feedforward neural network layer.
 - **Block:** Defines a Transformer block, which consists of a multi-head self-attention layer followed by a feedforward layer.
 - **BigramLanguageModel:** Defines the main language model using Transformer blocks.
6. **Model Training:** The code trains the language model using stochastic gradient descent. It computes the loss using cross-entropy between predicted logits and actual targets.
7. **Model Evaluation:** The code periodically evaluates the model's performance on both the training and validation sets.
8. **Model Generation:** After training, the code generates new text using the trained model. It starts with a given context and iteratively predicts the next character based on the previous context. This process continues for a specified number of iterations to generate a sequence of characters.

Overall, the code implements a simple character-level language model using the Transformer architecture, trains it on text data, evaluates its performance, and generates new text based on the learned patterns.

Μπορούμε να δούμε ότι η απάντηση του ChatGPT είναι συνοπτική και δίνει μια καλή περιγραφή των βασικών σημείων του κώδικα.

2.8.2 Αξιολόγηση κώδικα

Παρακάτω φαίνεται η απάντηση του μοντέλου στο prompt "Can you rate the above code?".

Sure, I can provide a rating based on several aspects of the code:

1. **Clarity and Readability:** The code is generally well-structured and easy to follow. Variable names are descriptive, and comments help explain the purpose of various sections. However, some parts could benefit from additional comments, particularly in the model components section to explain the purpose of each module.
2. **Efficiency:** The code makes efficient use of PyTorch's tensor operations and takes advantage of GPU acceleration if available. However, there may be some room for optimization, such as memory usage during training and generation.

3. **Functionality:** The code implements a complete workflow for training a character-level language model using a Transformer architecture. It includes data loading, model definition, training loop, evaluation, and text generation.
4. **Robustness:** The code includes error handling for CUDA availability (`device = 'cuda' if torch.cuda.is_available() else 'cpu'`) and ensures proper handling of tensor shapes throughout. However, additional error handling could be added for cases such as file I/O errors or unexpected input dimensions.
5. **Scalability:** The code is designed to handle training on both CPU and GPU (`'cuda' if torch.cuda.is_available() else 'cpu'`). However, scalability in terms of handling large datasets or distributed training could be improved with additional modifications.

Overall, I would rate the code as **4 out of 5**. It effectively achieves its purpose of training a character-level language model using a Transformer architecture, but there's still some room for improvement in terms of clarity, efficiency, and scalability.

Εδώ το ChatGPT κάνει παρατηρήσεις για τον κώδικα που αντικειμενικά μπορεί να μην είναι λανθασμένες, είναι όμως πολύ γενικές και δεν αξιολογούν τον κώδικα σε σχέση με τον εκπαιδευτικό του χαρακτήρα. Για παράδειγμα, κάνει αρκετές αναφορές στην απόδοση (GPU acceleration, scalability κλπ). Φυσικά πρέπει να λάβουμε υπόψιν ότι το prompt μας ήταν πολύ απλό χωρίς να δίνει καμία πληροφορία για την προέλευση ή τον σκοπό του κώδικα. Διαπιστώνουμε έτσι τη σημασία ενός σωστού prompt, που περιλαμβάνει όλες τις απαραίτητες πληροφορίες, ώστε να πάρουμε όσο το δυνατόν πιο χρήσιμη/βοηθητική απάντηση.

Τέλος μπορούμε να παρατηρήσουμε πως το ChatGPT έχει θεωρήσει πολύ κυριολεκτικά το prompt για αξιολόγηση του κώδικα δίνοντας μια συγκεκριμένη βαθμολογία 4 στα 5, ενώ μια τέτοια βαθμολογία μάλλον δεν έχει καμία ουσιαστική αξία.

2.8.3 Βελτίωση κώδικα

Σε αυτό το βήμα χρησιμοποιήσαμε το prompt "Can you rewrite (refactor) some parts of the above code?".

Certainly! Here are some suggestions for refactoring parts of the code to improve readability, efficiency, and maintainability:

1. **Separate Model Components into Modules:** Instead of defining the `Head`, `MultiHeadAttention`, `FeedForward`, and `Block` classes directly within the script, they could be moved to a separate module (e.g., `model_components.py`) for better organization. This would make the main script cleaner and easier to read.
2. **Use DataLoaders for Data Loading:** PyTorch's `DataLoader` class can simplify the process of loading batches of data. By creating a custom dataset class and using `DataLoader`, you can handle batching, shuffling, and other data preprocessing steps more efficiently.
3. **Consolidate Evaluation Code:** The evaluation code (`estimate_loss` function) can be consolidated into a single function that takes the split ('train' or 'val') as an argument. This would reduce code duplication and make it easier to maintain.
4. **Improve Logging:** Instead of printing loss values directly within the training loop, consider using a logging library (e.g., `logging` module in Python) to log training progress to a file or console. This provides more flexibility for controlling output and allows for easier monitoring of training.

5. **Encapsulate Model Training and Evaluation:** Define separate functions for model training (`train_model`) and evaluation (`evaluate_model`). This makes the training loop more modular and easier to understand, especially if additional training logic or evaluation metrics are added later.
6. **Parameterize File Paths:** Instead of hardcoding the file path for the input text file (`input.txt`), consider passing it as a command-line argument or as a parameter to the script. This makes the code more flexible and reusable with different input data.
7. **Optimize GPU Memory Usage:** To optimize GPU memory usage, consider detaching gradients after each iteration (`loss.backward()`) and using `optimizer.step()` within a `with torch.no_grad():` block. This prevents unnecessary memory consumption during backpropagation.
8. **Use Enumerate for Iteration:** In the training loop, use `enumerate` to loop over batches with their corresponding indices. This provides a cleaner and more idiomatic way to iterate over batches and track the current iteration number.

By implementing these refactorings, the code will become more organized, modular, and efficient, making it easier to maintain and extend in the future.

Σε αυτή την περίπτωση το ChatGPT δεν μας έδωσε καινούρια κομμάτια κώδικα παρά μόνο περιέγραψε κάποιες προτεινόμενες αλλαγές. Αυτό που διαπιστώνουμε και πάλι είναι ότι ενώ οι αλλαγές που προτείνει δεν είναι απαραίτητα κακές, μοιάζουν να είναι αρκετά γενικές, δηλαδή είναι πιθανό ότι θα ταίριαζαν σε οποιοδήποτε κομμάτι κώδικα χρησιμοποιεί το Pytorch.

Μπορούμε να δούμε επίσης πως έχει υποθέσει ότι ο κώδικας προέρχεται από κάποιο script και όχι notebook, ενώ προτείνει αλλαγές όπως τη χρήση logging που δεν ταιριάζουν με τον εκπαιδευτικό χαρακτήρα του κώδικα. Επιπλέον πουθενά δεν κάνει καμία συγκεκριμένη αναφορά σε κάποιο σημείο του κώδικα που του δώσαμε.

Θα λέγαμε ότι ενώ οι απαντήσεις του είναι σε γενικές γραμμές ικανοποιητικές, ειδικά στα δύο τελευταία ερωτήματα που του θέσαμε λείπει ένας βαθμός κατανόησης του σκοπού του κώδικα που εξετάζουμε και έτσι δεν είναι τόσο ουσιαστικές/χρήσιμες. Φυσικά παίζουν μεγάλο ρόλο στις απαντήσεις οι πληροφορίες που θα του δώσουμε και ο τρόπος που θα κάνουμε το κάθε ερώτημα.